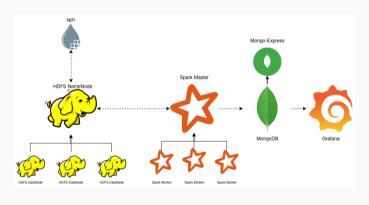
Analisi di dati di monitoraggio con Apache Spark

Sistemi e Architetture per Big Data - Progetto 1

Alessandro Lioi, 0333693

Architettura



Componenti:

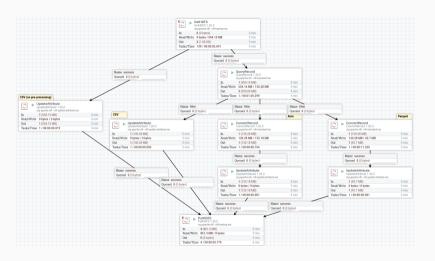
• HDFS: file system distribuito

• NiFi: pre-processing e data ingestion

• Spark: batch processing

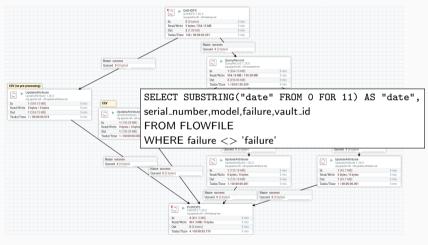
• MongoDB: data store NoSQL

• Grafana: visualizzazione



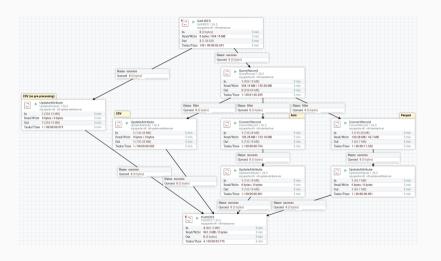
Processor usati

- **GetHDFS**: legge file da HDFS
- QueryRecord: seleziona le colonne di interesse
- ConvertRecord: converte dati da CSV in:
 - Apache Avro
 - Apache ParquetCSV
- UpdateAttribute: cambia nome file outpu
 - PutHDFS: salva su HDFS



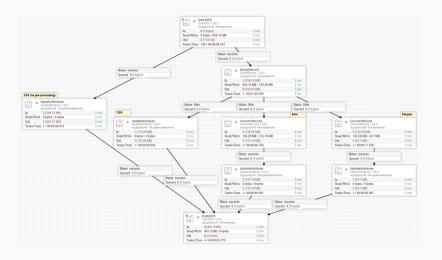
Processor usati

- GetHDFS: legge file da HDFS
- QueryRecord: seleziona le colonne di interesse
- ConvertRecord: converte dati da CSV in:
 - Apache AvroApache ParquetCSV
- UpdateAttribute: cambia nome file outpu
- PutHDFS: salva su HDFS



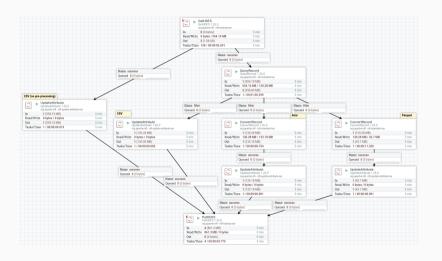
Processor usati

- **GetHDFS**: legge file da HDFS
- QueryRecord: seleziona le colonne di interesse
- ConvertRecord: converte dati da CSV in:
 - Apache Avro
 - Apache Parquet
 - CSV
- UpdateAttribute: cambia nome file output
- PutHDFS: salva su HDFS



Processor usati

- **GetHDFS**: legge file da HDFS
- QueryRecord: seleziona le colonne di interesse
- ConvertRecord: converte dati da CSV in:
 - Apache Avro
 - Apache Parquet
 - CSV
- UpdateAttribute: cambia nome file output
 - PutHDFS: salva su HDFS



Processor usati

- **GetHDFS**: legge file da HDFS
- QueryRecord: seleziona le colonne di interesse
- ConvertRecord: converte dati da CSV in:
 - Apache Avro
 - Apache Parquet
 - CSV
- UpdateAttribute: cambia nome file output
- PutHDFS: salva su HDFS

Tupla Originale:

date serial_number mo	del failure vault_id
-----------------------	----------------------

Tupla Risultante

key		value	
dat	е	$vault_id$	failure

```
rdd.map(lambda x: ((x[0], x[4]), x[3]))
.reduceByKey(add)
.filter(lambda x: x[1] in {2, 3, 4})
.map(lambda x: (x[0][0], x[0][1], x[1]))
.sortBy(lambda x: (-x[2], x[0], x[1]))
```

Tupla Originale:

date	serial_number	model	failure	vault_id	
------	---------------	-------	---------	----------	--

key		value
date	$vault_id$	failures_count

```
rdd.map(lambda x: ((x[0], x[4]), x[3]))
    .reduceByKey(add)
    .filter(lambda x: x[1] in {2, 3, 4})
    .map(lambda x: (x[0][0], x[0][1], x[1]))
    .sortBy(lambda x: (-x[2], x[0], x[1]))
```

Tupla Originale:

date	serial_number	model	failure	vault_id	
------	---------------	-------	---------	----------	--

Tupla Risultante

key		value	
date	vault_id	failures_count in 2,3,4	

```
rdd.map(lambda x: ((x[0], x[4]), x[3]))
.reduceByKey(add)
.filter(lambda x: x[1] in {2, 3, 4})
.map(lambda x: (x[0][0], x[0][1], x[1]))
.sortBy(lambda x: (-x[2], x[0], x[1]))
```

Tupla Originale:

late serial_numl	er model	failure	vault_id
------------------	----------	---------	----------

```
date | vault_id | failures_count in 2,3,4
```

```
rdd.map(lambda x: ((x[0], x[4]), x[3]))
.reduceByKey(add)
.filter(lambda x: x[1] in {2, 3, 4})
.map(lambda x: (x[0][0], x[0][1], x[1]))
.sortBy(lambda x: (-x[2], x[0], x[1]))
```

Tupla Originale:

date s	erial_number	model	failure	vault_id	
--------	--------------	-------	---------	----------	--

Tupla Risultante

```
date \uparrow vault_id \uparrow failures_count in 2,3,4 \downarrow
```

```
rdd.map(lambda x: ((x[0], x[4]), x[3]))
.reduceByKey(add)
.filter(lambda x: x[1] in {2, 3, 4})
.map(lambda x: (x[0][0], x[0][1], x[1]))
.sortBy(lambda x: (-x[2], x[0], x[1]))
```

Query 1 - DataFrame

In maniera analoga è implementata la query con i DataFrame

Tupla Originale:

	0				
date	serial_number	model	failure	vault_id	

key	value
model	failure

Tupla Originale:

date serial_number	model	failure	vault_id
--------------------	-------	---------	----------

key	value	
model	failures_count	

Tupla Originale:

date	serial_number	model	failure	vault_id

key	value	
model ↑	failures_count \	

- si trasforma in DataFrame
- si limitano a 10 risultati

Query 2 Ranking 1 - DataFrame

In maniera analoga è implementata la query con i DataFrame

```
vault_failures = rdd.map(lambda x: (x[4], x[3]))
                                                                     .reduceByKey(add)
Tupla Originale:
                                                vault_models = rdd.filter(lambda x: x[3] > 0)
        serial_number
                       model
                               failure
                                        vault_id
 date
                                                                   .map(lambda x: (x[4], x[2]))
                                                                   .groupBvKev()
                                                                   .mapValues(set)
Vault Failures
                                                vault_failures.join(vault_models)
   key
             value
                                                  .map(lambda x: (x[0], int(x[1][0]), ",".join(x[1][1])))
 vault_id
            failure
                                                  .sortBv(lambda x: (-x[1], x[0]))
                                                  .toDF(["vault_id", "failures_count", "list_of_models"])
                                                  .limit(10)
```

```
vault_failures = rdd.map(lambda x: (x[4], x[3]))
                                                                     .reduceByKey(add)
 Tupla Originale:
                                                vault_models = rdd.filter(lambda x: x[3] > 0)
                               failure
        serial_number
                       model
                                        vault_id
 date
                                                                   .map(lambda x: (x[4], x[2]))
                                                                   .groupBvKev()
                                                                   .mapValues(set)
Vault Failures
                                                vault_failures.join(vault_models)
   key
                 value
                                                  .map(lambda x: (x[0], int(x[1][0]), ",".join(x[1][1])))
 vault_id
            failures count
                                                  .sortBv(lambda x: (-x[1], x[0]))
                                                  .toDF(["vault_id", "failures_count", "list_of_models"])
                                                  .limit(10)
```

```
vault_failures = rdd.map(lambda x: (x[4], x[3]))
                                                                    .reduceByKey(add)
 Vault Failures
                                               vault_models = rdd.filter(lambda x: x[3] > 0)
                 value
   kev
                                                                   .map(lambda x: (x[4], x[2]))
 vault_id
            failures count
                                                                  .groupBvKev()
                                                                   .mapValues(set)
Vault Models
                                               _vault_failures.join(vault_models)
                        failure > 0
                model
                                      vault id
 date
        s num
                                                  .map(lambda x: (x[0], int(x[1][0]), ",".join(x[1][1])))
                                                  .sortBv(lambda x: (-x[1], x[0]))
                                                  .toDF(["vault_id", "failures_count", "list_of_models"])
                                                  .limit(10)
```

Vault Failureskeyvaluevault_idfailures_count

Vault Models

key	value		
$vault_id$	set_of_model		

Ranking 2 vault_id | failures_count | set_of_models

```
      vault_failures = rdd.map(lambda x: (x[4], x[3]))

      . reduceByKey(add)

      vault_models = rdd.filter(lambda x: x[3] > 0)

      . map(lambda x: (x[4], x[2]))

      . groupByKey()

      vault_failures.join(vault_models)

      . map(lambda x: (x[0], int(x[1][0]), ",".join(x[1][1])))

      . sortBy(lambda x: (-x[1], x[0]))

      . toDF(["vault_id", "failures_count", "list_of_models"])

      . limit(10)
```

- si trasforma in DataFrame
- si limitano a 10 risultati

Query 2 Ranking 2 - DataFrame

In maniera analoga è implementata la query con i DataFrame

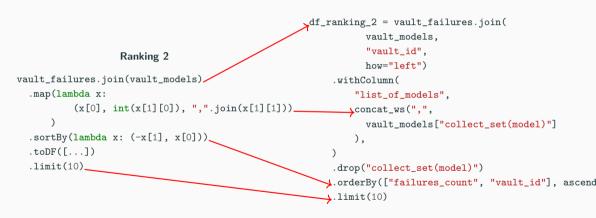
Query 2 Ranking 2 - DataFrame

In maniera analoga è implementata la query con i DataFrame

Vault Models

Query 2 Ranking 2 - DataFrame

In maniera analoga è implementata la query con i DataFrame



Grafana







Query 1

- Time Series
- Filtro sul Vault ID

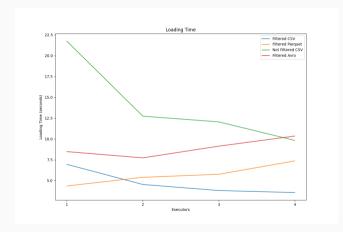
Query 2 Ranking 1

- Bar Chart
- Filtro sul Modello

Query 2 Ranking 2

- Bar Chart
- Filtro sul Modello e Vault ID

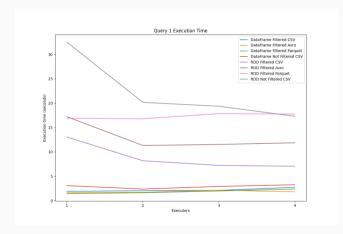
Performance - Tempi di Caricamento



- CSV filtrato più veloce all'aumentare degli executors
- Parquet formato con occupazione migliore

Formato	Peso
CSV Originale	581M
CSV Filtrato	137M
Apache Avro	140M
Apache Parquet	46M

Performance - Tempi di Esecuzione - Query 1



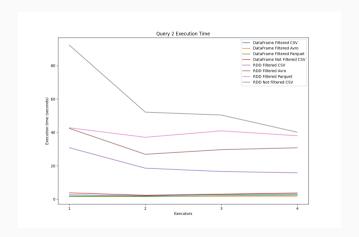
RDD

- CSV formato migliore
- Performance migliori all'aumentare degli executors

DataFrame

- Parquet formato migliore
- Prestazioni migliori

Performance - Tempi di Esecuzione - Query 2



RDD

ullet Situazione analoga alla Query 1

DataFrame

• Parquet e Avro formati migliori